文档转换助手示例文档

本文档用于演示 **doc-converter** 对四种格式的处理能力，涵盖标题、列表、表格、超链接、图片、流程图（Mermaid）与代码块。

功能特性

1. 支持 PDF、DOCX、HTML、Markdown 任意互转
2. 保留标题、段落、列表、表格等结构
3. 正确处理图片、流程图与嵌入附件
   - 图片保存为文件并在目标格式中引用
   - 流程结构转换为目标格式可表达的形式
4. 支持单文件与批量转换

结构对比表

格式	结构保留	图片	流程图	附件
PDF	启发式重建	裁剪导出	转为文本结构	EmbeddedFile
DOCX	完整	嵌入	组合形状提取	OLE 对象
HTML	完整	文件引用	Mermaid 渲染	链接引用
Markdown	完整	文件引用	Mermaid 代码块	链接引用

流程图示例

graph TD A["读取源文档"] --> B["解析为统一 IR"] B --> C{"目标格式"} C -->|PDF| D["HTML 排版引擎"] C -->|DOCX| E["python-docx 写入"] C -->|Markdown| F["Mermaid + 管道表格"] C -->|HTML| G["语义化 HTML"]

查看流程节点文本

1. 读取源文档
2. 解析为统一 IR
3. 目标格式
4. HTML 排版引擎
5. python-docx 写入

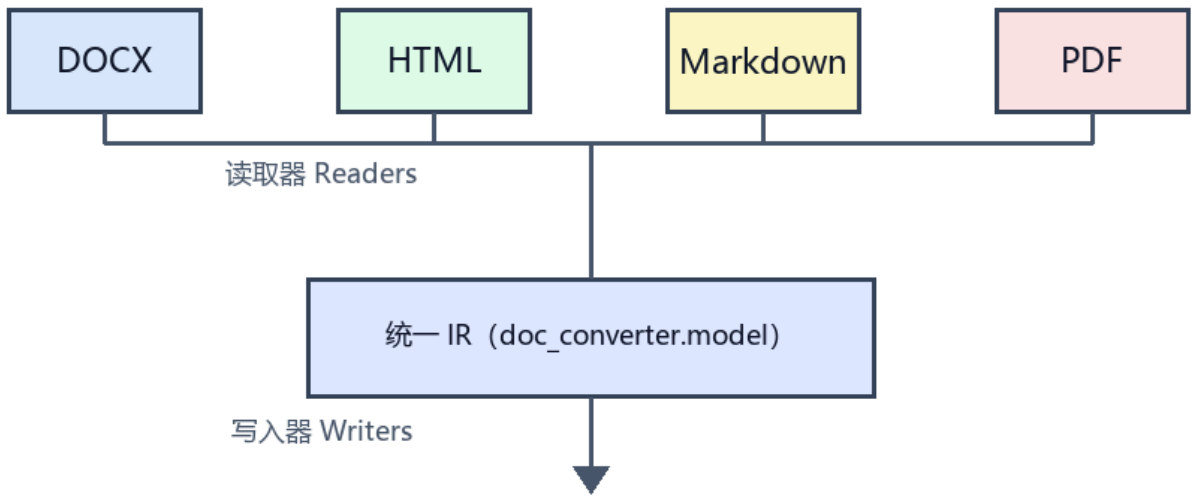
6. Mermaid + 管道表格
7. 语义化 HTML

代码示例

```
from doc_converter import convert

result = convert("sample.docx", target="md", output="out/")
print(result.output_path)
```

图片与链接



项目地址：https://github.com/example/doc-converter

引用与提示

> 提示：PDF 是版式驱动格式，标题层级由字号启发式推断。

—— 由示例生成器创建 ——